



Министерство науки и высшего образования Российской Федерации
Федеральное государственное бюджетное образовательное учреждение
высшего образования
«Московский государственный технический университет
имени Н. Э. Баумана
(национальный исследовательский университет)»
(МГТУ им. Н. Э. Баумана)

ФАКУЛЬТЕТ «Информатика и системы управления»

КАФЕДРА «Программное обеспечение ЭВМ и информационные технологии»

ОТЧЕТ

по рубежному контролю №1

по курсу «Анализ Алгоритмов»

на тему: «Организация асинхронного взаимодействия потоков вычисления на
примере конвейерных вычислений»

Студент ИУ7-53Б
(Группа)

(Подпись, дата)

Лысцев Н. Д.
(И. О. Фамилия)

Преподаватель

(Подпись, дата)

Волкова Л. Л.
(И. О. Фамилия)

2024 г.

СОДЕРЖАНИЕ

ВВЕДЕНИЕ	3
1 Аналитический раздел	4
1.1 Конвейерная обработка данных	4
1.2 N-граммы	4
1.3 Последовательная версия алгоритма	5
1.4 Параллельная версия алгоритма	5
1.5 Описание алгоритма	6
2 Конструкторский раздел	7
2.1 Разработка алгоритмов	7
2.1.1 Последовательный алгоритм работы стадий конвейера . .	7
2.1.2 Параллельный алгоритм работы стадий конвейера	8
3 Технологический раздел	14
3.1 Требования к программному обеспечению	14
3.2 Средства реализации	14
3.3 Сведения о модулях программы	15
3.4 Реализации алгоритмов	16
4 Исследовательский раздел	18
4.1 Технические характеристики	18
4.2 Проведение первого исследования	18
4.3 Проведение второго исследования	21
ЗАКЛЮЧЕНИЕ	24
СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ	25

ВВЕДЕНИЕ

Использование параллельной обработки открывает новые способы для ускорения работы программ. Конвейерная обработка является одним из примеров, где использование принципов параллельности помогает ускорить обработку данных. Суть та же, что и при работе реальных конвейерных лент — материал (данное) поступает на обработку, после окончания обработки материал передается на место следующего обработчика, при этом предыдущий обработчик не ждет полного цикла обработки материала, а получает новый материал и работает с ним.

Целью данной лабораторной работы является описание параллельных конвейерных вычислений.

Для достижения поставленной цели необходимо решить следующие задачи:

- 1) изучить и описать организацию конвейерной обработки данных;
- 2) описать алгоритмы обработки данных, которые будут использоваться в текущей лабораторной работе;
- 3) определить средства программной реализации;
- 4) реализовать программу, выполняющую конвейерную обработку с количеством лент не менее трех в однопоточной и многопоточной реализаций;
- 5) сравнить и проанализировать реализации алгоритмов по затраченному времени.

1 Аналитический раздел

В данном разделе рассмотрена информация, касающаяся основ конвейерной обработки данных.

1.1 Конвейерная обработка данных

Конвейер — организация вычислений, при которой увеличивается количество выполняемых инструкций за единицу времени за счет использования принципов параллельности.

Конвейеризация (или конвейерная обработка) в общем случае основана на разделении подлежащей исполнению функции на более мелкие части, называемые ступенями, и выделении для каждой из них отдельного блока аппаратуры. Производительность при этом возрастает, благодаря тому что одновременно на различных ступенях конвейера выполняется несколько команд. Конвейерная обработка такого рода широко применяется во всех современных быстродействующих процессорах.

Конвейеризация увеличивает пропускную способность процессора (количество команд, завершающихся в единицу времени), но она не сокращает время выполнения отдельной команды. В действительности она даже несколько увеличивает время выполнения каждой команды из-за накладных расходов, связанных с хранением промежуточных результатов. Однако увеличение пропускной способности означает, что программа будет выполняться быстрее по сравнению с простой, неконвейерной схемой [1].

1.2 N-граммы

Пусть задан некоторый конечный алфавит

$$V = w_i \tag{1.1}$$

где w_i — символ.

Языком $L(V)$ называют множество цепочек конечной длины из символов w_i . N-граммой на алфавите V (1.1) называют произвольную цепочку из $L(V)$ длиной N , например последовательность из N букв русского языка одного слова,

одной фразы, одного текста или, в более интересном случае, последовательность из грамматически допустимых описаний N подряд стоящих слов [2].

1.3 Последовательная версия алгоритма

Алгоритм составления файла словаря с количеством употреблений каждой N -граммы букв из одного слова в тексте на русском языке состоит из следующих шагов:

- 1) считывание текста в массив строк;
- 2) преобразование считанного текста (перевод букв в нижний регистр, удаление знаков препинания);
- 3) обработка каждой строки текста.

Обработка строки текста включает следующие шаги:

- 1) обработка каждого слова из строки текста;
- 2) выделение существующих в этом слове N -грамм;
- 3) увеличение количества выделенных N -грамм в словаре.

1.4 Параллельная версия алгоритма

В алгоритме составления файла словаря с количеством употреблений каждой N -граммы букв из одного слова в тексте на русском языке обработка строк текста происходит независимо, поэтому есть возможность произвести распараллеливание данных вычислений.

Для этого строки текста поровну распределяются между потоками. Каждый поток получает локальную копию словаря для N -грамм, производит вычисления над своим набором строк и после завершения работы всех потоков словари с количеством употреблений N -грамм каждого потока объединяются в один. Так как каждая строка массива передается в монопольное использование каждому потоку, не возникает конфликтов доступа к разделяемым ячейки памяти, следовательно, в использовании средства синхронизации в виде мьютекса нет необходимости.

1.5 Описание алгоритма

Ленты конвейера (обработчики) будут передавать друг другу заявки. Первый этап, или обработчик, будет формировать заявку, которая будет передаваться от этапа к этапу.

Заявка будет содержать:

- имя файла с исходным текстом на русском языке;
- имя выходного файла для словаря N -грамм;
- число N .
- временные отметки начала и конца выполнения каждой стадии обработки заявки.

В качестве операций, выполняющихся на конвейере, взяты следующие:

- 1) чтение текста на русском языке из файла;
- 2) выполнение параллельной версии алгоритма составления файла словаря с количеством употреблений каждой N -граммы букв из одного слова в тексте на русском языке в 2 потока;
- 3) логирование заявки в файл в формате: <имя_файла> + словарь N -грамм;

Вывод

В данном разделе было рассмотрено понятие конвейерной обработки, а также выбраны этапы обработки файлов, которые будут обрабатывать ленты конвейера. Также рассмотрено понятие N -грамм.

Программа будет получать на вход количество задач, число N , число строк в файле и длина каждой строки, а также выбор алгоритма: последовательный или конвейерный.

2 Конструкторский раздел

2.1 Разработка алгоритмов

2.1.1 Последовательный алгоритм работы стадий конвейера

На рисунке 2.1 представлен последовательный алгоритм работы стадий конвейера.

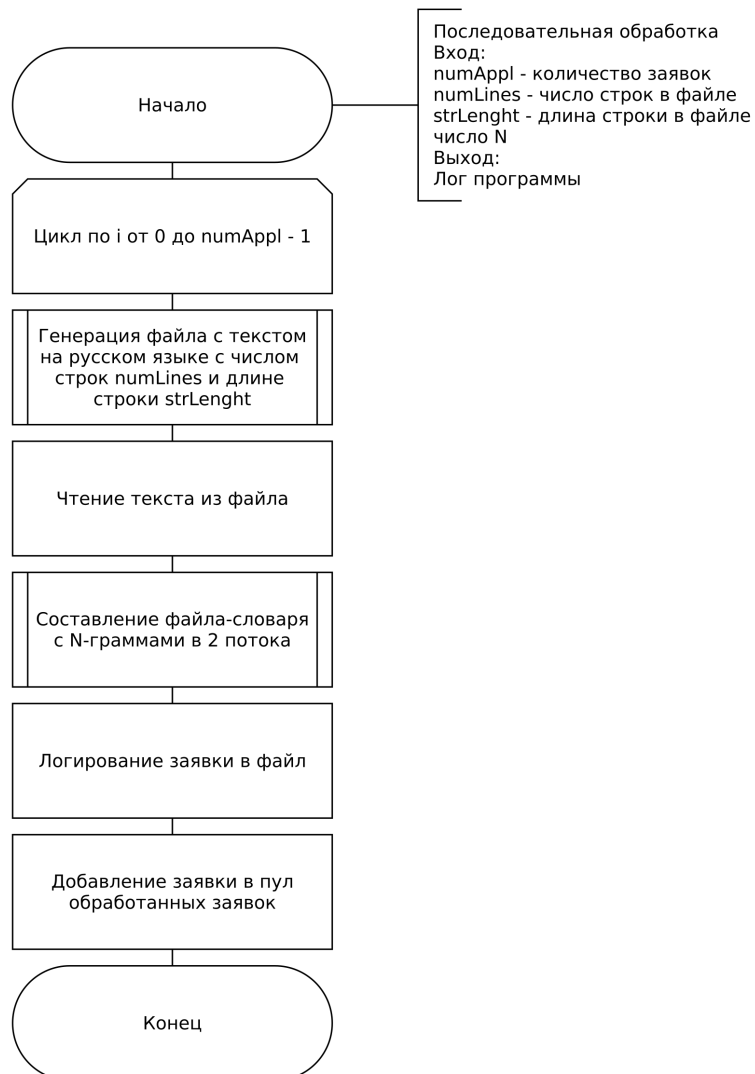


Рисунок 2.1 – Схема последовательного алгоритма работы стадий конвейера

2.1.2 Параллельный алгоритм работы стадий конвейера

Параллельная работа будет реализована с помощью добавления 3-х вспомогательных потоков, где каждый поток отвечает за свою стадию обработки.

Вспомогательному потоку в числе аргументов в качестве структуры будут переданы:

- имя файла с исходным текстом на русском языке;
- имя выходного файла для словаря N -грамм;
- число N .
- временные отметки начала и конца выполнения каждой стадии обработки заявки.

На рисунке 2.2 представлена схема алгоритма работы главного потока при параллельной работе стадий конвейера.

На рисунках 2.3 – 2.5 представлены схемы алгоритмов каждого из обработчиков (потоков) при параллельной работе.

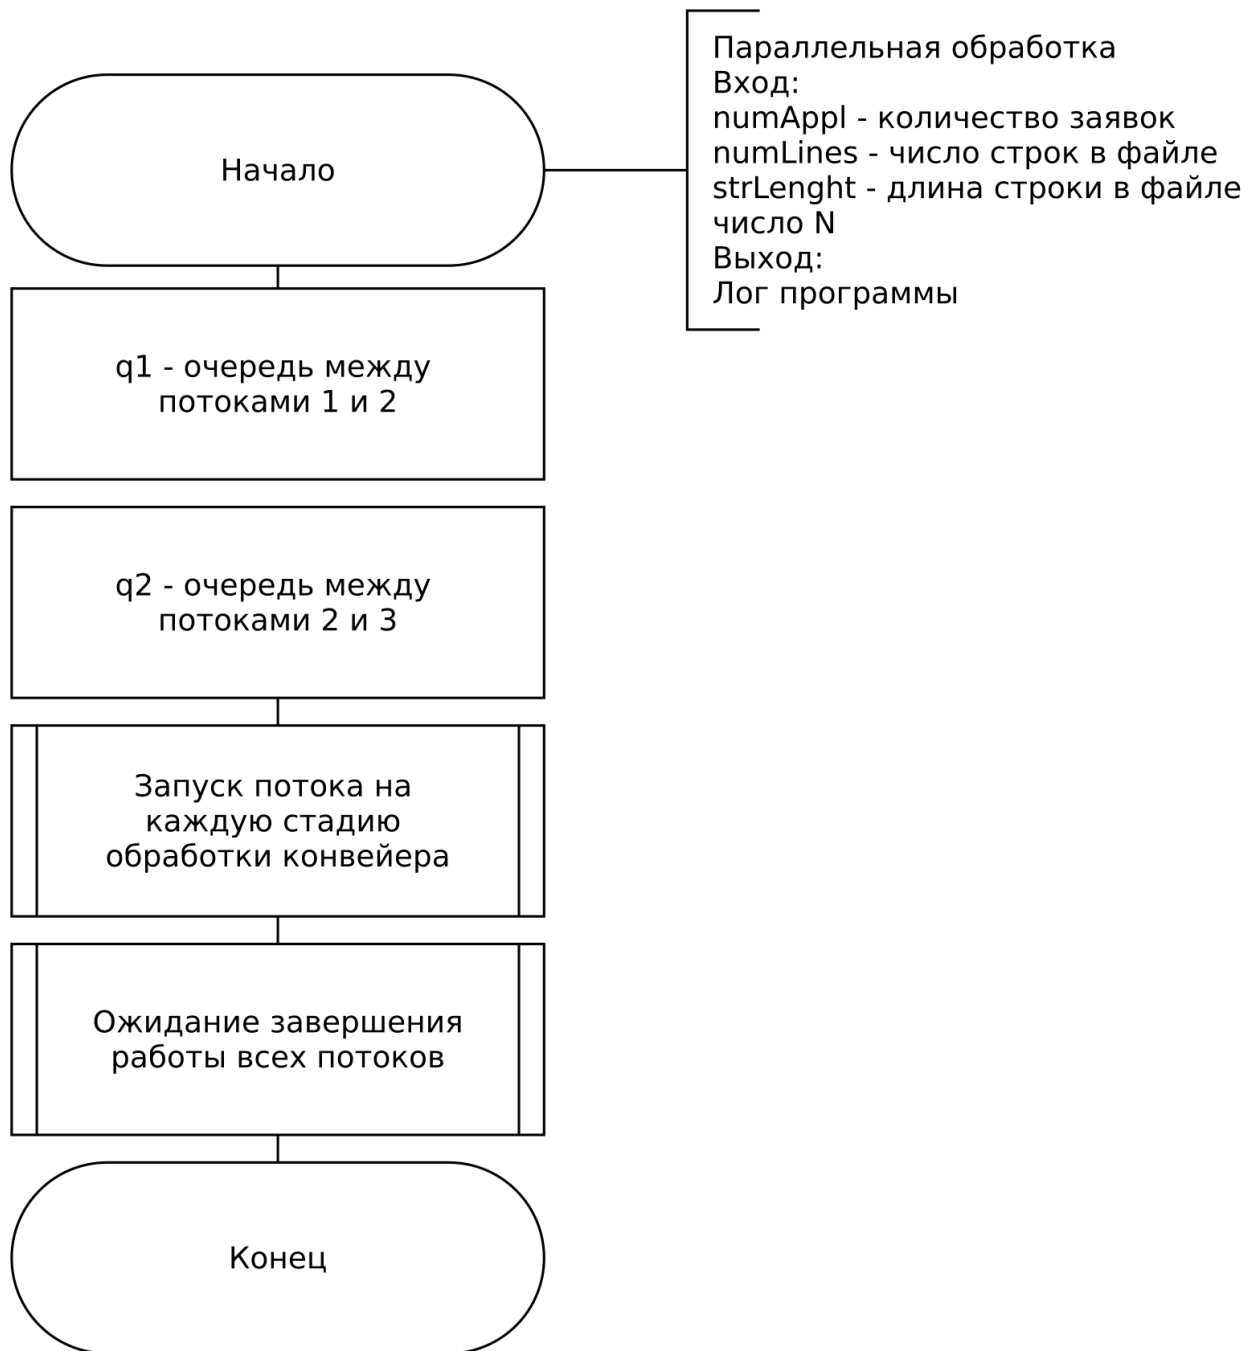


Рисунок 2.2 – Схема параллельного алгоритма работы стадий конвейера

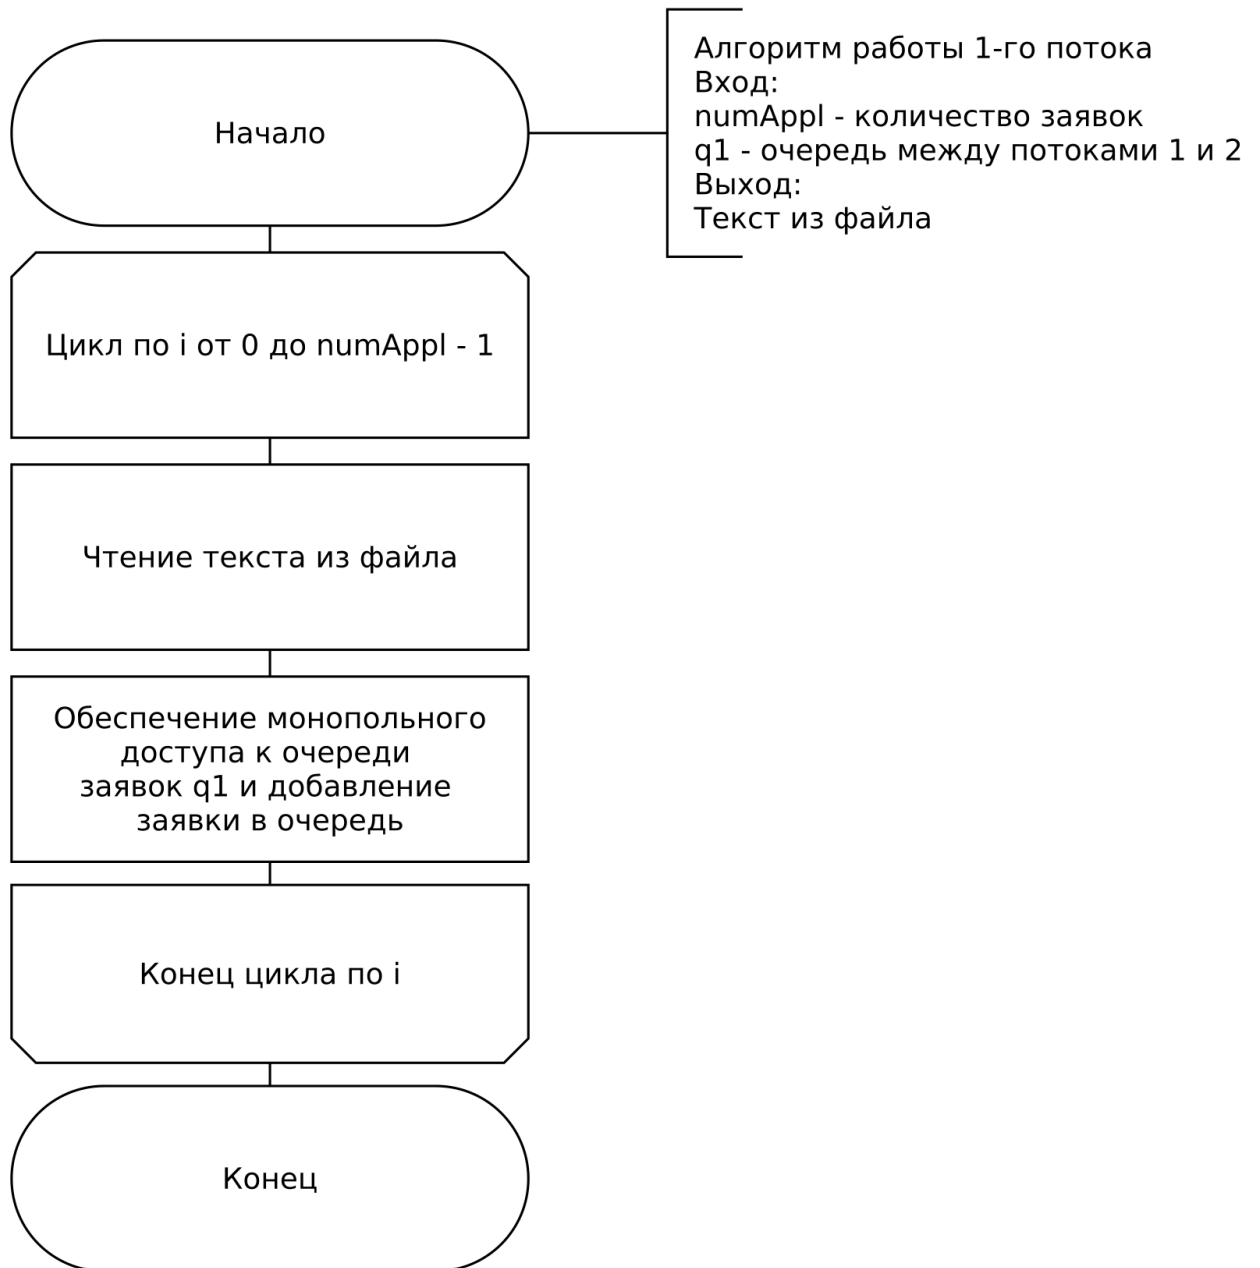


Рисунок 2.3 – Схема алгоритма потока, выполняющего чтение текстов из файлов

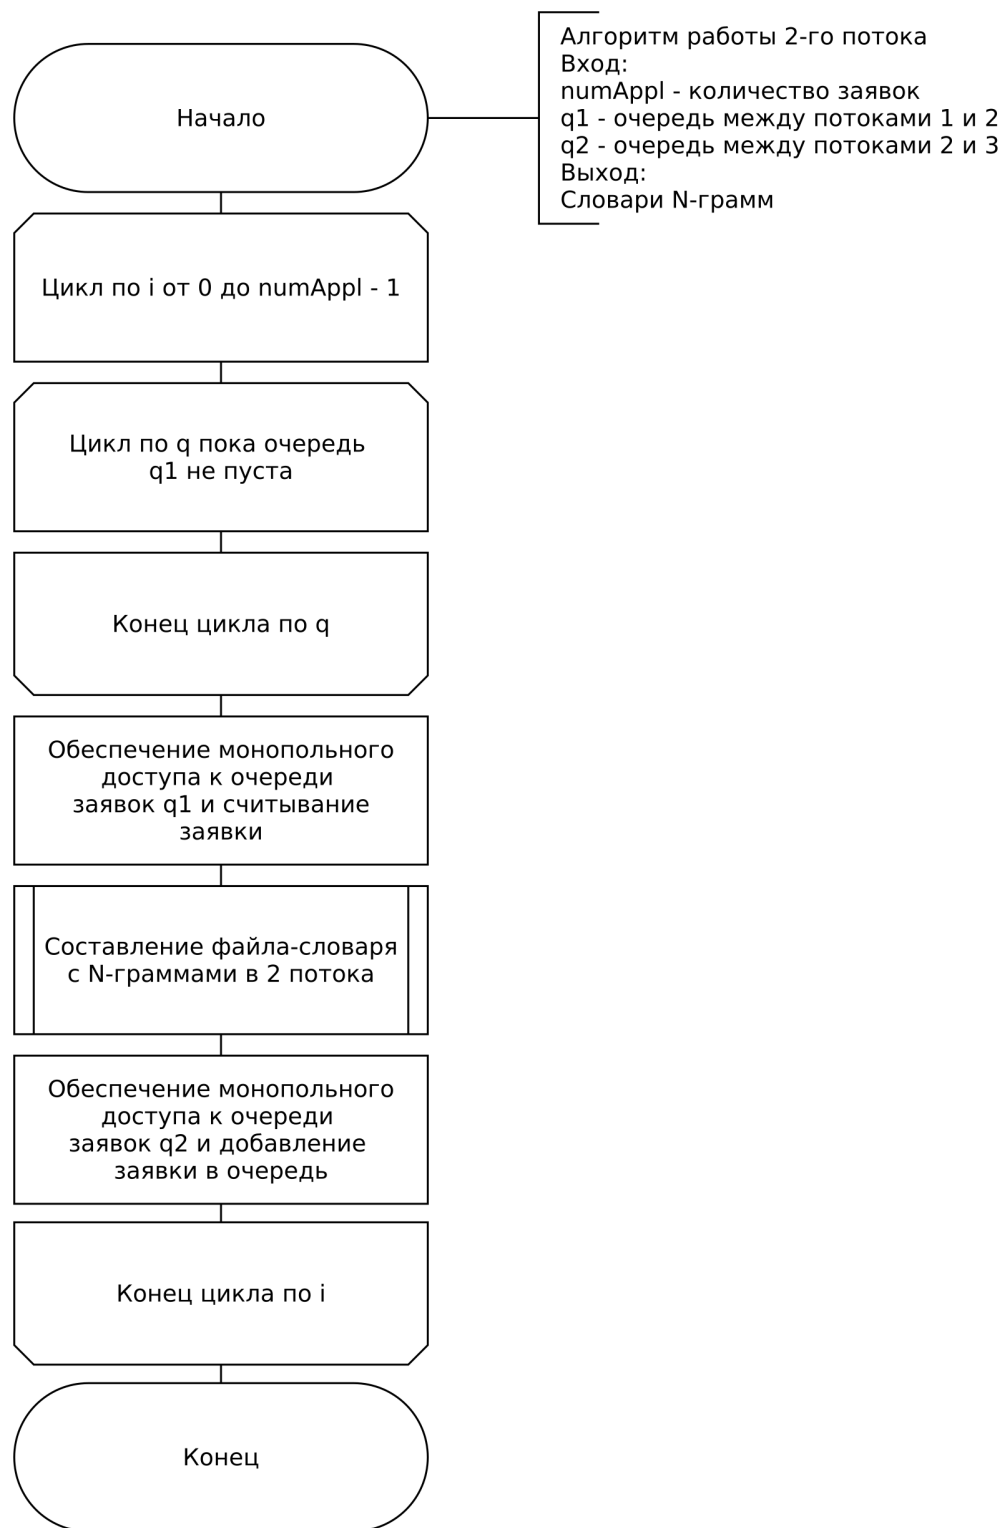


Рисунок 2.4 – Схема алгоритма потока, выполняющего составление файлов-словарей с N -граммами

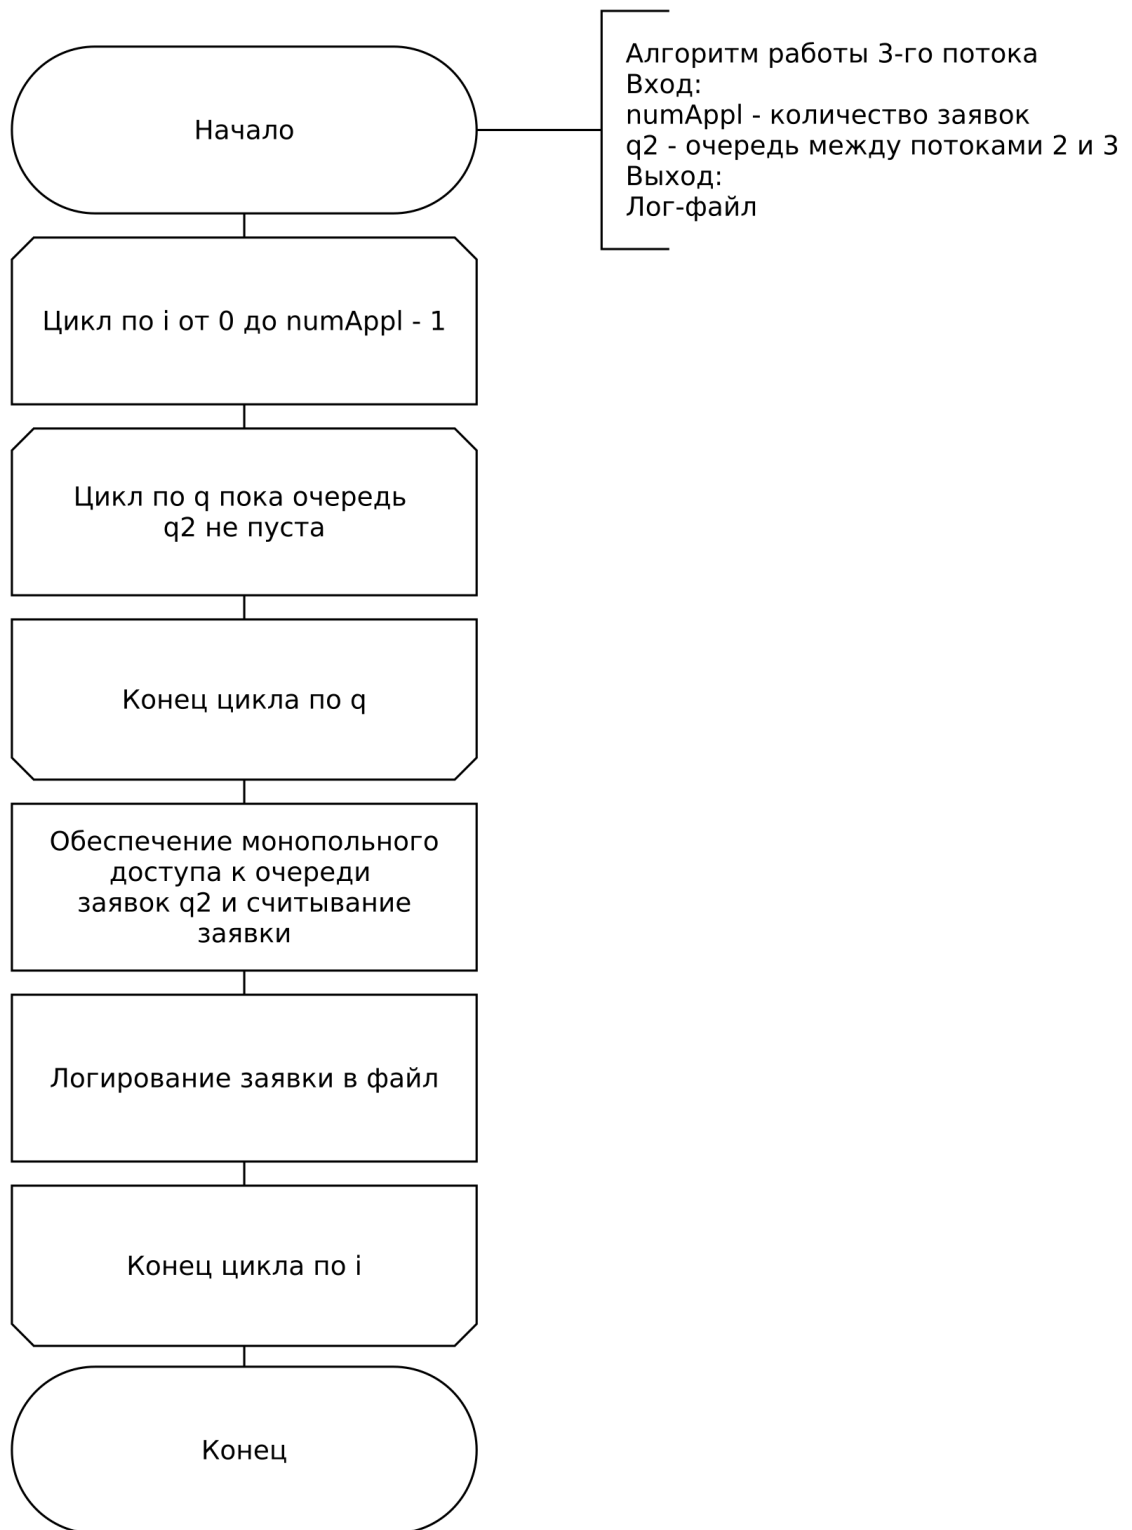


Рисунок 2.5 – Схема алгоритма потока, выполняющего логирование заявок в файл

Вывод

В данном разделе были представлены схемы последовательной и параллельной работы стадий конвейера.

3 Технологический раздел

В данном разделе будут перечислены требования к программному обеспечению, средства реализации и листинги кода.

3.1 Требования к программному обеспечению

К программе предъявляется ряд требований:

- на вход имя файла с текстом на русском языке, имя файла-словаря, число N — N -грамма;
- в программе для распараллеливания вычислений используются только нативные потоки;
- в результате работы программы получаем файл-словарь с количеством употреблений каждой N -граммы букв из одного слова в тексте на русском языке.

3.2 Средства реализации

В качестве языка программирования для этой лабораторной работы был выбран $C++$ [3] по следующим причинам:

- в $C++$ есть встроенный модуль *ctime*, предоставляющий необходимый функционал для замеров процессорного времени;
- в $C++$ есть встроенный модуль *thread* [4], предоставляющий необходимый интерфейс для работы с нативными потоками.

В качестве функции, которая будет осуществлять замеры процессорного времени, будет использована функция *clock_gettime* из встроенного модуля *ctime* [5].

3.3 Сведения о модулях программы

Программа состоит из пяти модулей:

- 1) `algorithms.cpp` — модуль, хранящий реализации последовательной и параллельной версии алгоритма составления файла словаря с количеством употреблений каждой N -граммы букв из одного слова в тексте на русском языке;
- 2) `processTime.cpp` — модуль, содержащий функцию для замера процессорного времени;
- 3) `timeMeasurements.cpp` — модуль, содержащий функции, позволяющие провести сравнительный анализ использования времени;
- 4) `main.cpp` — файл, содержащий точку входа в программу;
- 5) `task7` — модуль, содержащий набор скриптов для проведения замеров программы по времени и памяти и построения графиков по полученным данным.

3.4 Реализации алгоритмов

В листингах ?? – ?? представлена последовательная версия алгоритма составления файла словаря с количеством употреблений каждой N -граммы букв из одного слова в тексте на русском языке.

В листингах ?? – ?? представлена последовательная версия алгоритма составления файла словаря с количеством употреблений каждой N -граммы букв из одного слова в тексте на русском языке.

Вывод

В данном разделе были реализованы последовательная и параллельная версии алгоритма составления файла словаря с количеством употреблений каждой N -граммы букв из одного слова в тексте на русском языке.

4 Исследовательский раздел

В данном разделе будут проведены сравнения реализаций алгоритмов сортировки по времени работы и по затрачиваемой памяти.

4.1 Технические характеристики

Технические характеристики устройства, на котором проводились исследования:

- операционная система: Ubuntu 22.04.3 LTS x86_64 [6];
- оперативная память: 16 Гб;
- процессор: 11th Gen Intel® Core™ i7-1185G7 @ 3.00 ГГц × 8, 4 физических ядра, 8 логических ядер.

4.2 Проведение первого исследования

Цель первого исследования

Целью первого исследования является проведение сравнительного анализа времени работы последовательной версии алгоритма и параллельной версии алгоритма с одним вспомогательным потоком

Наборы варьируемых и фиксированных параметров

Замеры времени проводились для случайно сгенерированных файлом с числом строк, равным 10, 20, 30, 40, 50, 60, 70, 80, 90, 100.

В качестве фиксированного параметра было выбрано число N , равное 3.

Замеры времени для каждого размера 1000 раз. Время работы алгоритмов измерялось с использованием функции *clock_gettime* из встроенного модуля *ctime*.

Результаты первого исследования

Таблица 4.1 – Замер времени для файлов с числом строк от 10 до 100

Число строк в файле, единицы	Время, мкс	
	Последовательная версия	Параллельная версия с 1-м вспомогат. потоком
10	435.759	882.219
20	923.062	1 532.931
30	1 435.287	2 343.806
40	2 000.813	3 070.613
50	2 383.545	3 892.355
60	3 051.124	4 674.078
70	3 511.962	5 709.621
80	4 054.163	6 309.628
90	4 709.397	7 285.999
100	5 569.732	8 170.710

Из полученных данных следует, что однопоточный процесс демонстрирует более высокую эффективность по сравнению с процессом, включающим в себя создание вспомогательного потока для обработки всех строк файла. Это объясняется дополнительными временными затратами, связанными с созданием потока и передачей ему необходимых аргументов.

4.3 Проведение второго исследования

Цель второго исследования

Целью второго исследования является проведение сравнительного анализа времени работы параллельной версии алгоритма с разным числом потоков.

Наборы варьируемых и фиксированных параметров

Замеры времени проводились для числа потоков, равного 1, 2, 4, 8, 16, 34, 64.

В качестве фиксированного параметра было выбрано число N , равное 3 и число строк в файле с текстом, равное 100.

Замеры времени для каждого размера 1000 раз. Время работы алгоритмов измерялось с использованием функции *clock_gettime* из встроенного модуля *ctime*.

Результаты второго исследования

Оптимальные результаты по времени достигаются при использовании процесса с двумя дополнительными потоками, ответственными за вычисления. Для данной архитектуры вычислительной машины рекомендуется удерживаться при числе дополнительных потоков, равном 2. При увеличении числа потоков выше этого значения, расходы на поддержание потоков превышают выгоду от использования многопоточности, и функция времени в зависимости от количества потоков начинает увеличиваться.

Вывод

Для файла с текстом на русском языке размером в 100 строк:

- однопоточный процесс — 5569.732 мкс;
- параллельная версия с 1-м вспомогательным потоком — 8170.710;
- параллельная версия с 2-мя вспомогательными потоками — 7397.898;
- параллельная версия с 64-мя вспомогательными потоками — 12837.810;

Таким образом, для данного алгоритма использование дополнительных потоков приводит лишь к увеличению времени работы программы (даже с 2-мя потоками время работы программы в 1.33 раза больше, чем у однопоточного процесса). Для данной архитектуры вычислительной машины рекомендуется удерживаться при числе дополнительных потоков, равном 2.

ЗАКЛЮЧЕНИЕ

В ходе выполнения лабораторной работы были решены следующие задачи:

- 1) изучен и описан алгоритм составления файла словаря с количеством употреблений каждой N-граммы букв из одного слова в тексте на русском языке;
- 2) разработана последовательная и параллельная версии данного алгоритма;
- 3) реализована каждая версия алгоритма;
- 4) проведен сравнительный анализ алгоритмов по времени работы реализаций;
- 5) обоснованы полученные результаты в отчете к выполненной лабораторной работе.

Цель данной лабораторной работы, изучение принципов и получение навыков организации параллельного выполнения операций, также была достигнута.

В ходе выполнения лабораторной работы было выявлено, что в результате использования многопоточной реализации время выполнения процесса может как улучшиться, так и ухудшиться в зависимости от количества используемых потоков.

Для рассматриваемого алгоритма использование многопоточности приводит лишь к увеличению времени работы программы (даже с 2-мя потоками время работы программы в 1.33 раза больше, чем у однопоточного процесса). Для данной архитектуры вычислительной машины рекомендуется удерживаться при числе дополнительных потоков, равном 2.

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

1. Конвейерная обработка данных [Электронный ресурс]. — Режим доступа: <https://studfile.net/preview/1083252/page:25/> (дата обращения: 01.02.2024).
2. N-граммы в лингвистике [Электронный ресурс]. — Режим доступа: <https://cyberleninka.ru/article/n/n-grammy-v-lingvistike> (дата обращения: 27.01.2024).
3. Справочник по языку C++ [Электронный ресурс]. — Режим доступа: <https://learn.microsoft.com/ru-ru/cpp/cpp/cpp-language-reference?view=msvc-170> (дата обращения: 28.09.2022).
4. `std::thread` [Электронный ресурс]. — Режим доступа: <https://en.cppreference.com/w/cpp/thread/thread> (дата обращения: 27.01.2024).
5. `clock_getres` [Электронный ресурс]. — Режим доступа: https://pubs.opengroup.org/onlinepubs/9699919799/functions/clock_getres.html (дата обращения: 28.09.2022).
6. Ubuntu 22.04.3 LTS (Jammy Jellyfish) [Электронный ресурс]. — Режим доступа: <https://releases.ubuntu.com/22.04/> (дата обращения: 28.09.2022).